

字典学习的 K-SVD 算法分析

牛秀秀 华敏杰 狄燕飞 相鹏

(中国传媒大学 理工学部 北京 100024)

摘要: 分析了字典学习的 K-SVD 算法,通过引入 K-Means 计算方法,将 K-Means 方法推广到用于字典学习的 K-SVD 计算方法中;分析和描述了 K-SVD 计算过程,指出了 K-SVD 方法与 K-Means 方法之间的关系,最后观察图像数据训练用于稀疏表示的字典。

关键词: K-Means 方法;字典学习;稀疏表示;K-SVD 方法

中图分类号: TN911.73 **文献标识码:** A **文章编号:** 1673-4793(2017)01-0047-04

DOI:10.16196/j.cnki.issn.1673-4793.2017.01.008

The K-SVD Analysis of Dictionary Learning

NIU Xiu-xiu, HUA Ming-jie, DI Yan-fei, XIANG Peng

(School of Science, Communication University of China, Beijing 100024, China)

Abstract: The dictionary learning method i. e. the K-SVD algorithm has been analyzed. We have also extended to K-means to K-SVD method through using some ideas in K-means algorithm. The K-SVD algorithm to solve real problems has been analyzed and given in detailed steps. The differences and similarities between K-SVD and K-Means have been provided. The learned dictionary has been obtained by the observed image data based on the numerical experiments.

Key words: K-Means algorithm; dictionary learning; sparse representations; K-SVD algorithm

1 引言

图像去噪问题是非常重要的,不仅仅是因为在程序上的应用,而且作为最简单的反问题,给图像处理在技术和理念上提供了一个方便的平台。在过去的 50 年左右,许多人有着不同的观点,各种统计估计、空间自适应滤波器、偏微分方程、样条函数等等很多方向都在研究这个问题。在本文中主要专注一个特定的方法来解决图像去噪问题:在稀疏表示下的字典学习。

K-SVD 算法是 2006 年由以色列理工学院 Michal Aharon、Michael Elad 等人 [1] 提出来的,是一

种非常经典的字典训练算法,并且达到了很好的训练效果。其目的是解决下列等式的解:

$$Y = DX, \quad (1)$$

其中 D 是要训练的字典, X 是字典 D 对应的稀疏系数向量。当矩阵的维数过高时,即使在 Matlab 中也很难求得 (1) 的解。研究表明, K-SVD 算法可以比较简便的求解问题 (1)。

2 K-Means 算法

首先明确 K-Means 算法 [2-4] 解决的问题是:求解包含 K 个代码的码本,根据最近邻分配法则,对包含 N 个信号的集合 $Y = \{y_i\}_{i=1}^N$ ($N \gg K$)

收稿日期: 2016-4-15

作者简介: 牛秀秀 (1991-), 女 (汉族), 安徽省淮北人, 中国传媒大学硕士研究生. E-mail: 393908086@qq.com

在此码本上进行分类,然后得到最佳分类的问题。在本文中,稀疏编码 X 先利用追踪算法求出,作为已知条件。

在矢量量化(VQ)中,可以通过 K-Means 方法来对码本进行训练,假定码本为 $C = [c_1, c_2, \dots, c_K]$,代码是 C 中的列 c_i 。当码本 C 给定时,每个信号用最近(L^2 范数下)的一个代码表示。我们也可以写作 $y_i = Cx_i$,其中 $x_i = e_j$ 是自然基中的一个向量(除了第 j 个值为 1,其余为 0)。 j 满足

$$\forall_{k \neq j} \|y_i - Ce_k\|_2^2 \leq \|y_i - Ce_j\|_2^2$$

这种表示方法中, y_i 的方差为 $e_i^2 = \|y_i - Cx_i\|_2^2$,则 Y 的量化误差由 $E = \sum_{i=1}^N e_i^2 = \|Y - CX\|_F^2$ 来确定。从而 K-Means 的目标函数为

$$\min_C \{ \|Y - CX\|_F^2 \} \quad \forall i, x_i = e_k$$

我们可以发现 K-Means 算法就是一个对码本 C 进行更新迭代的过程。

3 K-SVD 算法——广义 K-Means 算法

在讲述 K-SVD 算法之前,我们首先要了解奇异值分解。奇异值分解就是假设 M 是一个 $m \times n$ 阶矩阵,其中的元素全部属于域 K (实数域或复数域)。如此则存在一个分解使得 $M = U\Delta V^*$,其中 U 是 $m \times m$ 阶酉矩阵; Δ 是半正定 $m \times n$ 阶对角矩阵;而 V^* 即 V 的共轭转置,是 $n \times n$ 阶酉矩阵。这样的分解就称作 M 的奇异值分解。 Δ 对角线上的元素 Δ_i , Δ_i 即为 M 的奇异值。

本文我们研究方程

$$\min_x \|x\|_0 \quad \text{s.t.} \quad y = Dx \quad (2)$$

其中,令 $D \in R^{n \times K}$ 代表字典, $y \in R^n$ 代表训练信号, $x \in R^K$ 代表训练信号的稀疏表示系数向量,给出 N 个训练信号的集合 $\{y_i\}_{i=1}^N$,其解向量的集合为 $\{x_i\}_{i=1}^N$ 。原问题(2)从线性组合角度来看,可以化成

$$\min_D \{ \|Y - DX\|_F^2 \} \quad \text{s.t.} \quad \forall i, \|x_i\|_0 \leq T_0 \quad (3)$$

我们可以发现求解(3)的过程就是一个迭代过程,具体迭代过程如下:

将字典 D 逐列进行更新:首先假设字典 D 和稀疏矩阵 X 都是固定的,下面要更新字典的第 k 列

d_k 。记稀疏矩阵 X 与 d_k 相乘的那行为 x_T^k (不同于 X 的第 k 列 x_k 的转置) 则(3)式中惩罚项可记为

$$\begin{aligned} \|Y - DX\|_F^2 &= \|Y - \sum_{j=1}^K d_j x_T^j\|_F^2 \\ &= \|(Y - \sum_{j \neq k} d_j x_T^j) - d_k x_T^k\|_F^2 = \|E_k - d_k x_T^k\|_F^2 \end{aligned} \quad (4)$$

其想法是将 DX 分解为 k 个秩为 1 的矩阵的和,假设其中的 $k-1$ 项都是固定的,剩下的 1 列就是要更新的,矩阵 E_k 表示的是去掉原子 d_k 的成分在所有 N 个样本中造成的误差。如果此时利用奇异值分解(SVD)来更新 d_k 和 x_T^k ,SVD 可以找到距离 E_k 最近的且秩为 1 的矩阵。但是其中的 x_T^k 不一定稀疏,所以更新的 d_k 不满足稀疏条件。也就是说用 SVD 得到的 x_T^k 更新向量中的非零值的位置和数量与原 x_T^k 不同,会出现“发散”现象。

因此,为了消除其“发散”现象,也就是先将 x_T^k 中所有的零元素缩减,仅保留非零值,然后再用 SVD 更新 d_k 和 x_T^k ,便不会出现“发散”现象。从而,定义集合 $\omega_k = \{i | 1 \leq i \leq N, x_T^k(i) \neq 0\}$ 即 ω_k 为用到 d_k 所有集合 $\{y_i\}$ 的索引所构成的集合,也就是 $x_T^k \neq 0$ 的点的索引值。定义 Ω_k 是一个 $N \times |\omega_k|$ 的矩阵,其中在点 $(\omega_k(i), i)$ 处为 1,其他处为 0。定义 $x_R^k = x_T^k \Omega_k$, $Y_R^k = Y \Omega_k$, $E_R^k = E_k \Omega_k$,从而三者分别是 x_T^k , Y , E_k 去掉 0 后的收缩结果, Y_R^k 为当前用到原子 d_k 样本的集合, E_R^k 为去掉不受原子 d_k 影响的样本,如果不考虑 d_k 在受其影响的样本中的成分时带来的误差。此时,可将式(4)化为

$$\|E_k \Omega_k - d_k x_T^k \Omega_k\|_F^2 = \|E_R^k - d_k x_R^k\|_F^2 \quad (5)$$

从而将 E_R^k 进行 SVD 分解,则 $E_R^k = U\Delta V^T$,即可对 d_k 进行更新,令 \tilde{d}_k 是 U 的第一列,则 \tilde{d}_k 是 d_k 更新的结果。同时,用 V 的第一列和 $\Delta(1,1)$ 的乘积对 x_R^k 进行更新。之后用新字典做稀疏分解,达到停止条件(达到迭代次数或者原信号与重构信号的误差率)则停止,否则迭代继续。此解决方案必须满足两个条件:1) D 的列保持规范化;2) 所有表示的支持度保持不变或者变小。

总结下来得到 K-SVD 算法过程:

1. 在已知稀疏矩阵 X 以及数据样本 $\{y_i\}_{i=1}^N$ 的情况下,给出要解决的问题:

$$\min_D \{ \|Y - DX\|_F^2 \} \quad \text{s.t.} \quad \forall i, \|x_i\|_0 \leq T_0$$

2. 给出初始字典 $D^{(0)} \in R^{n \times K}$, 其中的列向量都是 l^2 范数下的标准形式。给定 $J = 1$ 。

3. 对 $D^{(J-1)}$ 中的每列 $k = 1, 2, \dots, K$ 进行迭代:

(1) 通过 $E_k = Y - \sum_{j \neq k} d_j x_T^j$ 来计算误差;

(2) 由 E_k 通过 ω_k 的限定得到 E_R^k ;

(3) 对 E_R^k 进行奇异值分解得到 $E_R^k = U \Delta V^T$, 令 \tilde{d}_k 是 U 的第一列, 则 \tilde{d}_k 是 d_k 更新的结果。同时, 用 V 的第一列和 $\Delta(1, 1)$ 的乘积对 x_R^k 进行更新。

最后, $J = J + 1$ 继续重复迭代过程, 直到满足停止条件。

我们看到 K-SVD 可以看做 K-Means 的一种泛化形式, K-Means 算法中每个信号只能用一个原

子来近似表示, 而 K-SVD 算法可看做广义的矢量量化(VQ), 其中每个信号可以用多个原子的线性组合来表示。因此, 我们可以发现当 K-SVD 算法中要求的每个信号只用一个原子来近似时, K-SVD 算法就退化为 K-Means 算法。

4 数值实验

我们用 Matlab 对 K-SVD 算法进行了编程, 从脸图像数据库中找到训练数据, 其由 11000 例像素为 8×8 的小块构成, 按照他们的方差随机抽 500 个构成训练的图像如图 1。




图 1

为了运行 K-SVD 算法, 我们还要给出字典的大小为 64×256 , 得到训练字典的图像如图 2。

然后, 利用 K-SVD 算法得到的字典对观察图

像进行去噪, 此时选取两个图像的大小为 512×512 , 从而得到去噪后的图像如图 3。




图 2



图 3

5 结论

本文重点分析了 K-SVD 算法的计算过程,由于 K-SVD 算法针对不同的图像均有较好的适应性,并且能获得更好的恢复效果,因此,在图像学习中得到普遍运用。

参考文献

- [1] Aharon M, Elad M, Bruckstein A M. The K-SVD: An algorithm for designing of overcomplete dictionaries for sparse representation [J]. IEEE Trans Sig-

nal Process 2006 54(11): 4311-4322.

- [2] Pati Y C, Rezaiifar R, Krishnaprasad P S. Orthogonal matching pursuit: Recursive function approximation with applications to wavelet decomposition [C]. 27th Annual Asilomar Conf Signals, Systems, and Computers, 1993.
- [3] Mallat S, Zhang Z. Matching pursuits with time-frequency dictionaries [J]. IEEE Trans Signal Process, 1993 41(12): 3397-3415.
- [4] Gersho A, Gray R M. Vector Quantization and Signal Compression [M]. New York: Springer, 1991.

(责任编辑:王谦)

(上接第 40 页)

- [38] Whissell C, Fournier M, Pelland R. A dictionary of affect in language: Reliability, validity, and applications [J]. Perceptual and Motor Skills, 1986 62(3): 875-888.
- [39] Mao X, Xue Y L, Cheng L L. Harmonious graphics generating based on the 1/f function theory [J]. Chaos Solitons & Fractals, 2007 32(2): 521-525.
- [40] Sato K, Mitsukura Y. Analysis of the interaction between image and music focused on physical features [J]. Sice Conference, IEEE, 2012: 2179-2184.
- [41] Sato K, Mitsukura Y. Effects of music on image impression and relationship between impression and physical feature [J]. Human System Interactions (HSI), 2011 4th International Conference, IEEE 2011: 369-373.
- [42] Collignon O, Girard S, Gosselin F. Audio-visual integration of emotion expression [J]. Brain Research 2008 1242(4): 126-135.
- [43] Hinton G E, Osindero S, Teh Y W. A Fast Learning Algorithm for Deep Belief Nets [J]. Neural Computation 2006 18(7): 1527-1554.

- [44] Salakhutdinov R, Hinton G. An efficient learning procedure for deep Boltzmann machines [J]. Neural Computation 2012 24(8): 1967-2006.
- [45] Hinton G E, Salakhutdinov R R. Reducing the Dimensionality of Data with Neural Networks [J]. Science 2006 313(5786): 504-507.
- [46] Srivastava N, Salakhutdinov R. Multimodal Learning with Deep Boltzmann Machines [J]. Journal of Machine Learning Research 2014 15(8): 1967-2006.
- [47] Srivastava N, Salakhutdinov R. Learning representations for multimodal data with deep belief nets [J]. International Conference on Machine Learning Workshop (2012).
- [48] Rasiwasia N, Costa Pereira J, Coviello E. A new approach to cross-modal multimedia retrieval [J]. International Conference on Multimedia 2010, Firenze, Italy 2010: 251-260.
- [49] Zhang M L, Zhou Z H. A Review on Multi-Label Learning Algorithms [J]. IEEE Transactions on Knowledge & Data Engineering 2014 26(8): 1819-1837.

(责任编辑:宋金宝)